Université de Montpellier - Master informatique	28/04/2025
Contrôle - Traitement sémantique des données (HAI824)	Durée : 1 heure - Sans documents

Exercice 1 : Système OBDA (10 points)

On construit une application dans laquelle on s'intéresse principalement à des employés, leur département et les moyens de contact de ces employés : numéro de téléphone et/ou adresse mail. Pour simplifier, on ne fera pas la distinction entre un identifiant d'employé et son nom. On a 4 sources de données qui sont des bases de données relationnelles, dont les informations sont fiables mais généralement incomplètes. On veut donc intégrer les 4 sources de façon à avoir des informations plus complètes.

- La source 1 fournit le numéro de téléphone et le département de certains employés. Elle est modélisée par la relation `s1(Employé, Téléphone, Département)`
- La source 2 fournit l'adresse e-mail et le département de certains employés. Elle est modélisée par la relation `s2(Employé, EMail, Département)`
- La source 3 fournit le numéro de téléphone des employés du département `"RH"`. Elle est modélisée par la relation `s3(Employé, Téléphone)`.
- La source 4 fournit les départements, leur année de création et leur directeur actuel. Elle est modélisée par la relation `s4(Département, Année, Directeur)`. Cette source est la seule qui peut être supposée complète en ce qui concerne les départements et leurs directeurs actuels.

Question 1 On construit une ontologie dont les classes sont `Employé` et `Département` et les relations (propriétés) sont les suivantes :

- `aTel` : lie un employé à son numéro de téléphone
- `aMail` : lie un employé à son adresse mail
- `aDpt` : lie un employé à son département
- `aDir` : lie un département à son directeur
- `estDirDe` : lie un directeur au département qu'il dirige
- `aContact` : lie un employé à un moyen de contact : adresse mail ou numéro de téléphone.

Exprimez par des règles Datalog les liens sémantiques entre les relations de cette ontologie, ainsi que les signatures des relations (on ne s'intéresse qu'aux classes, pas aux types de données comme les chaînes de caractères). Vous veillerez à n'écrire que les règles nécessaires.

Question 2 On s'intéresse maintenant aux mappings des sources de données vers l'ontologie. On adoptera la syntaxe simplifiée de l'exemple ci-dessous, qui définit un mapping vers le prédicat `aMail` :

`SELECT Employé as X, EMail as Y FROM s2` $\Rightarrow$ `aMail(X,Y)`

2.a Etant donnée votre réponse à la question 1, quels sont les prédicats de l'ontologie (c'est-à-dire classes et relations) vers lesquels vous définiriez des mappings ? Expliquez.

2.b Ecrivez les mappings vers le prédicat `hasDpt`. Les sources de données étant incomplètes, on cherche à récupérer toutes les données permettant d'associer les employés et leur département. Vous pouvez nommer vos mappings (m_1, ...) si vous voulez les réutiliser par la suite (cf. question 6).

Question 3 On veut modéliser la relation entre un employé et son supérieur hiérarchique (direct), qui est le directeur de son département. Pour cela, on considère le prédicat `aSupH`, qui lie un employé à son supérieur hiérarchique (et on suppose qu'un employé peut être son propre supérieur hiérarchique).

Donnez une règle Datalog (qui n'utilise que le vocabulaire de l'ontologie) définissant `aSupH`.

Question 4 On adopte une approche de *matérialisation*. Quelles sont les étapes pour répondre à une requête (formulée avec le vocabulaire de l'ontologie) ? On suppose que cette requête est une requête conjonctive.

Question 5 On adopte une approche de *virtualisation*. Quelles sont les étapes pour répondre à une requête (formulée avec le vocabulaire de l'ontologie) ? On suppose que cette requête est une requête conjonctive.

Question 6 Illustrez votre réponse à la question 5 avec la requête suivante :

$q(Y) = \exists X.\ aDpt(X, \text{“RH”}) \wedge aContact(X, Y)$

Vous donnerez le résultat de chaque étape et veillerez à être cohérent avec vos réponses précédentes.

Exercice 2 : RDFS vers logique (5 pts)

On considère l'ensemble de triplets ci-dessous, sur le thème de Star Wars.

```
<:Luke :aPourArme _b1>
<_b1 rdf:type :SabreLaser>
<:Luke :pilote :XWing1>
<:XWing1 rdf:type :Vaisseau>
<:Vaisseau rdfs:subclass :Objet>
<:SabreLaser rdfs:subclass :Objet>
<:pilote rdfs:subproperty :utilise>
<:aPourArme rdfs:subproperty :utilise>
<:utilise rdfs:domain :Personnage>
```

Question 1. Donnez deux façons de traduire ces triplets en une base de connaissances logique, composée d'une base de faits F et d'une base de règles Datalog $\mathcal{R}$.

Si besoin, vous pouvez faire référence aux règles d'implication de RDFS, en expliquant comment vous les traduisez en logique.

Question 2. Pour chacune des deux traductions, peut-on exprimer en logique les requêtes SPARQL suivantes ? Si oui, donnez la requête obtenue, ainsi que l'ensemble de réponses à cette requête sur les faits et règles de la question 1. Si non, expliquez brièvement pourquoi la requête n'est pas exprimable.

1. `SELECT ?P ?O WHERE { ?P :utilise ?O. }`
2. `SELECT ?P ?T WHERE {?P :utilise ?O. ?O rdf:type ?T. ?T rdfs:subclass :Objet. }`

Exercice 3 : Correspondances entre Datalog et UCQ (5 pts et + (Q4))

Question 1. On rappelle qu'une union de requêtes conjonctives (UCQ) a la forme suivante :

$$Q(x_1, \ldots, x_k) = q_1(x_1, \ldots, x_k) \vee \ldots q_n(x_1, \ldots, x_k)$$

où chaque q_i est une requête conjonctive dont les variables réponses sont $x_1, \ldots, x_k$.

Comment traduire une UCQ de cette forme en une requête Datalog équivalente, c'est-à-dire retournant le même ensemble de réponses quelle que soit la base de faits ?

Question 2. Montrez par un exemple (simple) que la traduction de Datalog vers UCQ n'est pas toujours possible.

Question 3. Certaines requêtes Datalog peuvent se traduire en UCQ, en voici un exemple :

$r(x_1) \wedge r(y_1) \rightarrow p(x_1, y_1)$
$t(x_2, y_2) \rightarrow p(x_2, y_2)$
$s(x_3) \rightarrow r(x_3)$
$p(x_4, y_4) \rightarrow ans(y_4)$

3.a Donner une UCQ équivalente à cette requête, en supposant que tous les prédicats (sauf *ans*) peuvent apparaitre dans la base de faits.

Indication : Pensez au mécanisme de réécriture de requête avec des règles.

3.b Même question en supposant que les seuls prédicats extensionnels (ceux de la base de faits) sont t et s.

Question 4. Plus généralement, pouvez-vous donner une condition sur la structure de la requête Datalog qui assure l'existence d'une traduction en UCQ ? Et dans ce cas, comment calculez-vous une traduction ?

Bien entendu, on cherchera une condition la moins restrictive possible.